

1차 리뷰

- 기존의 COVID-19 입국 심사 프로토콜
 - 특징 : 크게 네 가지 유형으로 색깔을 써서 나라를 구별
 - 역학적 지표 근거
 - 해결해야 될 문제:
 - under-reporting
 - symptomatic population biases - 양성이 음성보다 적은 불균형
 - reporting delays
- Eva : 최초의 완전 알고리즘 실시간 강화 학습 시스템(the first fully algorithmic, real-time, reinforcement learning system)
 - 절차
 - 도착 승객은 도착 24시간 전에 여행 및 인구 통계 정보를 제출
 - 이 데이터와 이전 승객의 테스트 결과를 기반으로 Eva는 테스트할 승객 집합을 선택
 - 자가 격리, Eva 업데이트
- 문제 세팅 - Decision Problem
 1. 입국 지역 e에 도착하는 x-승객에 대해 수행할 테스트의 개수
 - 제약 조건
 - Budget Constraint
 - Arrivals Constraint
 2. 나라 별 색 지정
- Eva 를 이용한 '여행자별 COVID-19 유병률 추정' 방법 (보충자료 2.2) → 잘 이해가 안 가는 부분
 - empirical Bayes estimation strategy assuming country-based types → 이 추정값을 바탕으로 지난 14일간의 테스트 결과에 대해 LASSO 로지스틱 회귀를 수행

- LASSO
 - indicator variables (one-hot encoding) 변수들로 이루어진 모델
 - 차원 축소
 - 질문: PCA가 아니라 LASSO인 이유
- 경험적 베이즈 추정(empirical Bayes estimation)
 - 샘플 0 ~ 100
 - 사전적으로 가지고 있는 믿음(이 나라의 유병률)을 섞는 것
 - 베타분포에서 a, b 업데이트
 - 데이터가 쌓일 수록 베타분포가
 - 기존의 데이터 문제를 해결해줌
 - arrival rates 가 나라마다 천차만별
 - 불균형 - few positive cases
 - 초기 단계에서 리스크가 적게(너무 극단적이지 않게, 안정적으로)
- The testing allocation decision
 - algorithmic and balances two objectives. **(Multi-Armed Bandits)**
 - exploitation
 - 예측된 유병률이 높은 것부터 집합에
 - 단점: 놓치고 있는 사각지대
 - exploration
 - 유병률이 높을 가능성이 있는 것에 투자
 - 정확한 추정치가 없는 여행자 유형에 몇 가지 테스트를 전략적으로 할당
 - **“nonstationary, contextual, batched bandit problem with delayed feedback and constraints”**

(고정되지 않은, 상황에 맞는)

 - **nonstationary:** 발병률이 계속 실제로 바뀔 수 있다(ex: 카지노, 시간에 따라 승률 확률이 실제로 바뀌는)

- **contextual** : 상황이 주어지고(승객 정보가 주어지는), **exploit/explo**, 액션이 두 개(**arm**은 하나, **당긴다/안당긴다**) , 환자에 따라 승객에 따라 달라짐
- **batched** : **Decision making** 하루 단위로 한 번에 선택을 함
- **delayed feedback**: 이틀 후에 결과가 나옴
- **constraints** : 정해진 데이터의 수가 한정되어 있다(Arrivals Constraint: 도착하는 승객의 수가 정해짐)

→ 이것은 Greedy 전략과는 다름.

- Greedy 전략의 단점
 - 현재 유병률이 높은 유형에 검사를 할당하려고 했다면 며칠 안에 **중간 정도의 유병률을 가진 다른 많은 유형에 대한 최근 검사 데이터를 얻지 못할 것**
 - COVID-19 유병률이 예기치 않게 빠르게 급증할 수 있기 때문에 알고리즘에 '사각지대(blind spot)'가 남고 심각한 공중 보건 위험을 초래할 수 있음.

• 고유한 문제 - 'pipeline' tests

- 결과가 아직 반환되지 않은 할당된 테스트
- 테스트에서 받을 것으로 예상되는 모델 정보를 바탕으로?
- 새로운 알고리즘 기술을 도입하여.. 고정되지 않은 일괄 설정에서 탐색과 활용의 균형을 효과적으로 맞출 수 있음

"we introduce a novel algorithmic technique of certainty-equivalent updates to model information we expect to receive from these tests, allowing us to effectively balance exploration and exploitation in nonstationary, batched settings."

- 'Gittins 지수' 도입 (2.3 Allocating Test Results)
 - Upper Confidence Bound
 - Thompson Sampling
 - optimistic gittins indices → 이 아이디어 채택

- Gittins 지수 알고리즘 (정확히 이해안됨) → 좀 더 이해 필요
 - UCB
 1. 가장 높은 지수를 가진 타입 테스트
 2. 피드백을 확인하고 해당 타입의 사후 확률을 업데이트
 3. 해당 타입의 새로운 지수 계산
 4. 1 ~ 3 과정 업데이트
 - 이 알고리즘의 문제점
 - 하루 동안 지수 값이 일정(즉각적인 피드백을 받지 않음)
 → batched bandit literature [15, 16] 이 부분적으로 해결
- 그레이 리스트 - 특히 위험한 국가를 포함하는 리스트
 - 완전히 알고리즘이 아니라 사람의 의견이 포함

targeted testing - 을 위해서 reinforcement learning

- 무작위 감시 검사(Random surveillance testing)
 - Eva와 동일한 효과를 얻으려면 무작위 테스트는 각 진입 지점에서 **85% 더 많은 테스트**가 필요
 - 입국자가 감소함에 따라 검사를 받은 입국자의 비율이 증가하여 표적 검사의 가치가 감소→ 즉, **Eva의 타겟팅은 테스트가 부족할 때 가장 효과적**
 - counterfactual analysis using **inverse propensity weighting(IPW)** → 벤치마크 정책의 성과를 Eva의 성과와 비교하여 공정한 비교 가능.

"As arrivals dropped, the fraction of arrivals tested increased, thereby reducing the value of targeted testing. In other words, Eva's targeting is most effective when tests are scarce."